

Maison Delcourt

Chocobot : rendre un chatbot
conforme, sobre et fiable

Hazel et Edilene



Le point de départ




Recommandations dangereuses

12 réponses sur **18** proposaient un coffret contenant l'**allergène signalé**



Trop de données personnelles

Allergies et âge des **enfants** conservés, **profil** complet **affiché** dans les **logs**




Consommation élevée

100 % des messages envoyés au **gros modèle**, environ **21 000 tokens** par série de tests



Pannes invisibles

Aucune erreur dans les **logs**, et **/health** répondait toujours « **ok** »



Le cadre légal

RGPD

Une allergie est une donnée de santé, protégée (art. 9). Il faut ne collecter que le nécessaire et ne pas la conserver plus longtemps qu'utile (art. 5).

AI Act

ChocoBot est un système à risque limité (il ne relève d'aucun domaine de l'annexe III). Il doit indiquer clairement qu'il s'agit d'une IA (art. 50).

Règlement Omnibus

Nouveau calendrier. Le marquage des textes générés est attendu au plus tard le 2 décembre 2026.


Licence Llama 3.2

mention « Built with Llama » obligatoire, et interdiction de présenter les réponses comme écrites par un humain.

Conformité :

ce que nous avons changé


Purge automatique des données



Identification IA



Protection Back-Office



Sobriété : ce que nous avons changé

« La requête la plus sobre est celle qu'on n'envoie pas au modèle. »




Réponses fixes pour
les question
fréquentes
(horaires/livraison)




Petit modèle pour les
messages simples
(merci, bonjour, ok),
gros modèle pour tout
conseil



Réponses plus
courtes et historique
limité aux derniers
échanges



Consommation
mesurée avec
CodeCarbon,
avant et après





Fiabilité : ce que nous avons changé




Logs structurés

avec un identifiant pour suivre chaque requête




Sentry

pour être alerté des erreurs,
configuré pour ne transmettre
aucune donnée personnelle



Catalogue vérifié au démarrage

(format et cohérence des allergènes)




/health 503

quand la base, le modèle
ou le catalogue pose
problème



Modèle de secours


si le premier ne répond pas



Script de tests


pour refaire toutes les
mesures en une commande




« Une panne qu'on ne voit pas est plus
dangereuse qu'une panne qu'on voit. »



Les résultats avant / après

Indicateur	Avant	Aujourd'hui
Tokens pour une conversation type (15 messages)	21 461	4 874 (-77 %)
Énergie par message	0,099 Wh	0,027 Wh (-72 %)
Latence moyenne	5,5 s	2,3 s
Recommandations dangereuses pour un enfant allergique (relues à la main)	12 sur 18	0 sur 18
Horaires inventés	9 conversations sur 9	0 (réponse fixe)
Panne du modèle : erreur visible et alerte	non	oui (logs JSON et Sentry)
Catalogue corrompu détecté	non	oui (message clair, /health en 503)
Données personnelles dans les logs	profil complet à chaque message	aucun texte de client
5 clients en même temps	3 sur 5 servis	2 sur 5 servis (régression, voir plus bas)





Maison Delcourt
ARTISAN CHOCOLATIER · LILLE

Ce qui reste à faire

Requêtes simultanées

Si **plusieurs** clients écrivent en **même temps**, seulement **2 sur 5** seront servis.

Refus abusifs

Le bot **affirme** parfois que **tous** les coffrets contiennent des noisettes


Sécurité

Limiter la taille des messages et le **nombre** de requêtes


Conformité

Mention « Built with Llama » et **marquage** des textes générés





Ce que nous retenons



Mesurer avant de corriger :

sans les chiffres de départ, impossible de prouver nos améliorations




Conformité et sobriété vont ensemble :

moins de données, c'est moins de risques et moins d'énergie



Rendre les erreurs visibles :

c'est la base de la fiabilité





Merci !

Des questions ?

